

ENGENHARIA DE PROMPT: CONCEITOS, FUNDAMENTOS E APLICAÇÕES, COM ÊNFASE EM ROBÓTICA

PROMPT ENGINEERING: CONCEPTS, FOUNDATIONS, AND APPLICATIONS, WITH AN EMPHASIS ON ROBOTICS

Márcio Mendonça¹; Vitor Blanc Milani²; Marco Antônio Ferreira Finocchio³; Francisco de Assis Scannavino Junior⁴; Rodrigo Henrique Cunha Palácios⁵; Wagner Fontes Godoy⁶; Marco Antônio de Matos Laia⁷

1 Pós-Doutorado em Inteligência Artificial. Doutor em Engenharia Elétrica e Informática Industrial. Docente no Programa de Pós-Graduação em Engenharia Mecânica (PPGEM CP/PG) da Universidade Tecnológica Federal do Paraná, Cornélio Procópio – PR, mendonca@utfpr.edu.br

2 Engenheiro Mecânico. Especialista em Automação de Processos Industriais e Robótica. Mestrando em Engenharia Mecânica no Programa de Pós-Graduação em Engenharia Mecânica (PPGEM CP/PG) da Universidade Tecnológica Federal do Paraná, Cornélio Procópio – PR, eng.vmilani@gmail.com

3 Mestre em Engenharia Elétrica. Docente vinculado ao Departamento Acadêmico de Elétrica – Universidade Tecnológica Federal do Paraná, Cornélio Procópio – PR, mafinocchio@utfpr.edu.br

4 Doutor em Física Computacional. Docente vinculado ao Departamento Acadêmico de Elétrica – Universidade Tecnológica Federal do Paraná, Cornélio Procópio – PR, franciscojunior@utfpr.edu.br

5 Doutor em Engenharia Elétrica. Docente vinculado ao Departamento Acadêmico de Computação Universidade Tecnológica Federal do Paraná, Cornélio Procópio – PR, rodrigopalacios@utfpr.edu.br

6 Doutor em Engenharia Elétrica. Docente vinculado ao Departamento Acadêmico de Elétrica – Universidade Tecnológica Federal do Paraná, Cornélio Procópio – PR, wagnergodoy@utfpr.edu.br

7 Doutor em Física. Docente na Universidade Federal de São João del-Rei, Minas Gerais – MG.

RESUMO

Este artigo apresenta os fundamentos da engenharia de *prompt* como ferramenta essencial na interação entre humanos e sistemas de inteligência artificial, com ênfase na robótica. São abordados os conceitos principais, arquiteturas envolvidas, como o modelo GPT da OpenAI, além de aplicações práticas como geração de imagens, comandos em linguagem natural e modelagem matemática de robôs. A pesquisa demonstra como *prompts* bem formulados potencializam os resultados gerados por modelos de linguagem, evidenciando sua utilidade em áreas como cidades inteligentes e robótica industrial. Destaca-se a importância de clareza e precisão nos comandos e as limitações ainda existentes nos modelos, além da comparação entre ferramentas como ChatGPT e Grok. A engenharia de *prompt* desponta como uma competência central para profissionais da área tecnológica. E, finalmente esse trabalho se encerra com uma conclusão e sugere futuros trabalhos

Palavras-chave: interação humano-máquina, *deep learning*, automação inteligente, sistemas autônomos.

ABSTRACT

This article presents the fundamentals of prompt engineering as an essential tool for human interaction with artificial intelligence systems, emphasizing robotics. It explores key concepts, model architectures such as OpenAI's GPT, and practical applications, including image generation, natural language commands, and mathematical modeling of robots. The study demonstrates how well-designed prompts enhance the output of language models, showing their usefulness in fields such as smart cities and industrial robotics. The importance of clarity and precision in instructions is highlighted, as well as current model limitations and a comparison between tools like ChatGPT and Grok. Prompt engineering is emerging as a core skill for professionals in the technology sector. Finally, this work ends with a conclusion and suggestions for future work.

Keywords: human-machine interaction, deep learning, intelligent automation, autonomous systems.

1 INTRODUÇÃO

A engenharia de *prompt* (*Prompt Engineering*) tem se destacado como uma abordagem inovadora para otimizar a interação entre humanos e modelos de Inteligência Artificial (IA), com aplicações crescentes na área de robótica (Brown *et al.*, 2020; Wang *et al.*, 2024). Fundamentada na capacidade de traduzir intenções em instruções claras para sistemas de IA, essa engenharia visa promover uma comunicação mais eficiente e precisa, permitindo que algoritmos interpretem comandos em linguagem natural de maneira mais robusta (Radford *et al.*, 2019). Assim, sua adoção em sistemas robóticos, sobretudo quando integrados a soluções clássicas possibilita maior adaptabilidade e desempenho em tarefas complexas, o que é particularmente valioso em cenários como manufatura avançada, assistência pessoal e operações autônomas (Liu *et al.*, 2023).


Entretanto, apesar dos benefícios evidentes, o desafio de contornar vieses algorítmicos e a necessidade de ajustes contínuos no desenvolvimento de *prompts* mostram que a Engenharia de *Prompt* ainda exige atenção e refinamento constantes (Bender *et al.*, 2021). Esses fatores são cruciais para garantir o alinhamento ético e eficiente das aplicações robóticas, sobretudo em contextos em que a interação humano-robô precisa ser intuitiva e confiável.

Neste trabalho, são abordados os conceitos fundamentais da Engenharia de *Prompt*, estratégias para a formulação de instruções eficazes e exemplos práticos de aplicação em diferentes domínios da robótica. Ao final, discute-se a relevância desse campo emergente para o futuro dos sistemas inteligentes e propõem-se possíveis caminhos para pesquisas futuras.

Ressalta-se que todo avanço tecnológico traz consequências e mudanças no comportamento profissional, como sugere ser a entrada desses *chatbots*, como por exemplo o Grok do grupo xAI, Gemini da Google e o mais conhecido e utilizado, o *ChatGPT* da Open AI, entre tantos outros como Claude e *Deepseek*.

Uma consequência impactante ocorreu recentemente nos Estados Unidos. Uma pesquisa realizada pela LawGeex, mostra que a precisão das inteligências artificiais é melhor que de advogados humanos em atividades rotineiras, conforme observado na figura 1.

Figura 1 – Gráfico comparativo entre IA's e advogados humanos.



Fonte: LawGeex (2018).

De acordo com LawGeex (2018), a comparação do desempenho de sistemas de IA com advogados em tarefas de revisão contratual evidenciou uma maior precisão dos algoritmos. A imagem compara o desempenho de uma IA com o de advogados na tarefa de revisar e aprovar contratos do dia a dia, destacando que o sistema de Inteligência Artificial atingiu uma taxa de precisão de 94%, enquanto os advogados alcançaram 85%, posto isso, pode-se deduzir que outras profissões possuem impacto semelhante, inclusive as de área de tecnologia como as áreas de engenharia, computação e ensino, por exemplo.

Posto isso a motivação e objetivo desse artigo é fundamentar e conscientizar que profissionais que dominem essas ferramentas certamente estarão à frente de seus concorrentes, como engenheiros por exemplo. De acordo com Brynjolfsson e McAfee (2014), a adoção de ferramentas tecnológicas impacta a competitividade no mercado de trabalho, evidenciando a importância de profissionais que dominem essas inovações.

Já no contexto da robótica, a engenharia de *prompt* representa uma nova fronteira de interação entre humanos e máquinas. Ao permitir que comandos em linguagem natural sejam convertidos em ações executáveis, essa abordagem aproxima os modelos de linguagem de sistemas físicos, abrindo espaço para aplicações em robótica colaborativa, ensino de programação de robôs e controle autônomo contextualizado. Tal integração torna-se especialmente relevante em ambientes industriais e laboratoriais, onde a adaptação rápida de tarefas é essencial.

Ressalta-se que não é escopo desse artigo uma revisão da literatura, devido a amplitude e impacto dessa área emergente, e sim os elementos supracitados.

2 FUNDAMENTAÇÃO TEÓRICA

A engenharia de *prompt* é a forma de utilizar o conhecimento armazenado nos *chatbots*, a versão GPT 4o lançada já há alguns meses pela Open AI é da ordem de trilhões de *terabytes* de dados.

A inteligência artificial pode ser classificada em três grandes áreas: aprendizado de máquinas, do inglês *machine learning*, *lógica Fuzzy*, Zadeh, L. A. (1965) e sistemas bioinspirados, como por exemplo algoritmos genéticos Holland, J. H. (1975).

Os *chatbots* pertencem a divisão de aprendizado de máquinas, o qual iniciou no final dos anos 50 e início dos anos 60, em tempo essas técnicas não evoluíram devido a necessidade de processamento computacional na época, vários trabalhos podem ser considerados como o início dessa divisão da Inteligência artificial, como por exemplo o trabalho de Samuel, A. L. (1959).

Devido a vasto campo dessa divisão da I.A. não é escopo dessa investigação científica aprofundar sobre I.A. e suas divisões e sim fundamentar que os *chatbots*, em especial o *ChatGPT*, foco dessa pesquisa utilizam as redes *transformers*, consideradas redes neurais profundas, do inglês as *deep learning*, as quais podem ter centenas de milhares de camadas e é considerada como o maior desenvolvimento da área.


A imagem da figura 2 apresentada descreve, em formato piramidal, uma visão geral da arquitetura utilizada pelo *ChatGPT*, caracterizada como um *transformer* composto apenas pelo decodificador (“*decoder-only*”). Essa estrutura destaca aspectos fundamentais da construção de modelos de linguagem de grande porte (*Large Language Models* – LLMs) e pode ser correlacionada com os trabalhos de Vaswani *et al.* (2017), Radford *et al.* (2018) e Brown *et al.* (2020).

A pirâmide na imagem possui cinco níveis, cada um descrevendo componentes ou propriedades centrais da arquitetura.

Cabe ressaltar que essas redes neurais passam por um pré-treinamento com dados massivos trilhões de *tokens*, partes de uma palavra, extraídos da internet, livros e artigos. *Common Crawl* fornece *pentabytes* de texto da *web*. Para refinamento do aprendizado, outra

técnica de aprendizagem de máquinas é empregada, o aprendizado sem supervisão.

Figura 2 – Arquitetura *Decoder-Only Transformer* utilizada no *ChatGPT*.



Fonte: *OpenAI* (2024).

No âmbito dos modelos de linguagem baseados em *deep learning*, a geração sequencial ocupa uma posição central, onde o modelo prevê cada *token* subsequente com base no contexto fornecido pelos *tokens* anteriores. Este princípio fundamenta os modelos autorregressivos, nos quais o treinamento consiste em aprender a distribuição condicional do próximo *token*, dado um histórico prévio (Graves, 2013). Durante a inferência, essa metodologia permite que o texto seja produzido progressivamente, *token a token*, mantendo coerência e consistência discursiva.

Embora originalmente voltados para tarefas linguísticas, os modelos de linguagem vêm sendo adaptados para aplicações robóticas, especialmente na interpretação de comandos em linguagem natural e no planejamento de trajetórias autônomas. Pesquisas recentes (Wang *et al.*, 2024) demonstram que os *Large Language Models* (LLM) podem atuar como camadas cognitivas em arquiteturas de controle de robôs, traduzindo instruções verbais em parâmetros cinemáticos e comportamentais. Dessa forma, os princípios teóricos que sustentam o GPT também se estendem à robótica cognitiva e à automação inteligente.

Complementando essa abordagem, os modelos como GPT (*Generative Pretrained Transformer*) utilizam camadas especializadas que incluem mecanismos sofisticados para capturar relações contextuais. Um dos principais mecanismos é o *Multi-Head Attention*, introduzido por Vaswani *et al.* (2017), que possibilita ao modelo identificar interdependências entre diferentes posições de uma sequência textual de maneira paralela. Cada "cabeça" de atenção (*attention head*) foca em diferentes aspectos contextuais, potencializando a capacidade expressiva do modelo. Posteriormente, as redes *Feed Forward* (FFN), compostas por camadas densas com funções de ativação não lineares intermediárias, refinam as representações obtidas pela atenção. Ainda, a técnica de normalização das camadas (*Layer Normalization*), proposta por Ba *et al.* (2016), desempenha um papel fundamental na estabilização do treinamento, permitindo maior profundidade sem comprometer a estabilidade numérica.

Outro elemento-chave nesses modelos são as conexões residuais, inicialmente introduzidas por He *et al.* (2016). Essas conexões promovem a ligação direta entre a entrada e a saída de cada bloco de camadas, garantindo um fluxo eficiente dos gradientes durante o treinamento e mitigando problemas como o desaparecimento ou a explosão de gradientes em redes profundas. Além disso, essas conexões permitem que o modelo aprenda de maneira mais eficaz, transmitindo informações "brutas" diretamente para camadas superiores.

Na estrutura da arquitetura GPT, diversos *decoders* são empilhados, cada um constituído pelos módulos mencionados anteriormente: *Multi-Head Attention*, *Feed Forward Networks* e conexões residuais. A profundidade (número de camadas) e a largura (dimensionalidade interna das representações) dos modelos são aspectos diretamente relacionados à sua capacidade representacional. Modelos mais robustos, como o GPT-3, chegam a possuir até 96 camadas em determinadas configurações, suportando bilhões de parâmetros (Brown *et al.*, 2020).

A base dessa abordagem teórica culmina na escala expressiva desses modelos. O GPT-3, por exemplo, conta com aproximadamente 175 bilhões de parâmetros, enquanto o GPT-4 é estimado em uma magnitude ainda maior, possivelmente na ordem de trilhões de parâmetros, embora números exatos ainda não tenham sido publicamente confirmados. Essa elevada quantidade de parâmetros permite aos modelos capturar padrões linguísticos e contextuais altamente complexos. Por outro lado, implica significativas demandas computacionais, tanto no treinamento, exigindo *hardware* especializado como GPUs ou TPUs em larga escala, quanto na fase de inferência (Kaplan *et al.*, 2020).

De um modo geral as a arquitetura “*Decoder-Only Transformer*” representada na imagem reflete o princípio básico de modelos GPT: camadas empilhadas de atenção multi-cabeças e redes *feed-forward*, com conexões residuais e normalizações de camada, organizadas de forma a prever o próximo *token* em uma sequência. Esse paradigma de auto regressão possibilita a geração de texto coerente, aproveitando a capacidade de “atenção” contextual profunda. A grande quantidade de parâmetros (bilhões ou trilhões) encontrada em modelos como GPT-3 e GPT-4 está diretamente associada a ganhos de desempenho em tarefas de compreensão e geração de linguagem natural, mas também acarreta desafios de escalabilidade e custo computacional.

E, finalmente, essa estrutura modular, demonstrada pela pirâmide, reforça o estado da arte na modelagem de linguagem natural, culminando em modelos capazes de realizar uma ampla variedade de tarefas de forma flexível.


2.1 Aspectos filosófico

De acordo com um dos maiores pesquisadores da área de Inteligência Artificial e Robótica, Rodney Brooks (2002), chefe do laboratório de robótica do MIT, há um descompasso fundamental entre a capacidade de resolução de problemas das inteligências artificiais e a forma como os seres humanos constroem conhecimento e abstraem o mundo real. Segundo o autor, embora os sistemas de IA sejam capazes de lidar com tarefas de altíssima complexidade computacional como reconhecimento de padrões, planejamento de trajetórias e controle de processos eles ainda não possuem os mecanismos de aprendizado experiencial e adaptação contextual característicos da cognição humana.

Brooks argumenta que, na robótica, esse contraste se manifesta de forma particularmente evidente: robôs podem superar humanos em velocidade, precisão e repetibilidade, mas ainda são limitados quando o ambiente exige interpretação situacional ou tomada de decisão sob incerteza. Essas limitações reforçam a importância de integrar abordagens cognitivas e linguísticas — como a engenharia de prompt — aos sistemas autônomos, possibilitando que robôs compreendam intenções humanas expressas em linguagem natural e ajam de maneira contextualizada.

Posto isso, a Figura 3 apresenta um dos slides da MIT Generative AI Week, evento no qual foram discutidos justamente esses contrastes conceituais entre o raciocínio humano e o comportamento das inteligências artificiais. A imagem, originalmente em inglês, sintetiza as principais dualidades observadas pela comunidade científica contemporânea, conforme destacado por Brooks e outros pesquisadores do MIT.

Figura 3 – Figura apresentada na semana Generativa do MIT



Fonte: MIT Generative AI week (2023).

A imagem apresenta um palestrante durante o evento MIT *Generative AI Week*, exibindo um slide que discute os limites e possibilidades dos sistemas de inteligência artificial generativa. O conteúdo do slide organiza esses limites em pares conceituais contrastantes, referenciando pesquisadores relevantes em cada eixo de análise: “imitação vs. inovação”, conforme discutido por Yiu, Kosoy e Gopnik (2023); “geração vs. compreensão” e tema recorrente nas pesquisas de Yejin Choi com outros pesquisadores, por exemplo Liu *et al.* (2023) e Zhou *et al.* (2020). Outro ponto é a “memorização vs. raciocínio”, associado aos estudos de Melanie Mitchell; e “reagir vs. planejar”, em referência às contribuições de Yann LeCun (2019). Tais contrastes evidenciam as atuais lacunas cognitivas dos modelos de IA em relação à cognição humana.

De forma resumida, o ponto principal é que diferentes pesquisadores apontam limites das abordagens atuais de IA em termos de criatividade, entendimento profundo, capacidade de raciocínio e planejamento, contrastando-as com meros processos de imitação e geração de texto ou comportamento. De um modo geral, pode-se concluir que a capacidade humana pode perder na velocidade e solução de problemas não triviais, porém supera em alguns aspectos esses *chatbots*, como por exemplo o *ChatGPT* que usa uma rede neural profunda com trilhões de informações. Um exemplo já clássico disso é a área da robótica colaborativa que emprega capacidade humana de tomadas de decisões e robóticas de velocidade e precisão sem fadiga (Mendonça *et al.*, 2025).

2.2 Engenharia de *prompt*, conceitos, fundamentos e exemplos

Engenharia de *prompt*: O que é e por que é importante? Engenharia de *prompt* é a arte e a ciência de projetar *prompts* eficazes para modelos de linguagem. *Prompts* bem elaborados podem gerar resultados mais precisos e relevantes, maximizando o potencial de ferramentas como o ChatGPT.

De um modo mais específico, a engenharia de *prompt* (em inglês, *prompt engineering*) é a prática de desenvolver e otimizar instruções ou entradas (*prompts*) fornecidas a sistemas de inteligência artificial, especialmente modelos de linguagem como o GPT, para que eles possam gerar respostas mais precisas, relevantes e úteis. O foco está em criar *prompts* que guiem o comportamento do modelo de forma eficiente para que ele produza o resultado desejado. Na prática, em problemas com maior nível de complexidade escrever um *prompt* em inglês pode aumentar a qualidade da resposta. Isso ocorre porque 70 a 90% da massa de dados empregados no treinamento da rede *transformer* é no idioma universal, inglês (Mendonça, *et al.*, 2025)

3 METODOLOGIA

A metodologia adotada neste estudo foi de natureza experimental e exploratória, com o objetivo de avaliar a aplicabilidade da engenharia de *prompt* em contextos de geração de código e modelagem robótica. Buscou-se investigar como diferentes modelos de linguagem podem interpretar instruções em linguagem natural e produzir resultados úteis em tarefas práticas, como geração de imagens, elaboração de textos técnicos e desenvolvimento de código para simulação robótica.

O trabalho foi desenvolvido em três etapas principais: Seleção dos modelos, Formulação dos *prompts* e critérios de avaliação.

3.1 Seleção dos modelos e ferramentas

Nesta etapa foram escolhidos dois modelos de *Large Language Model* (LLMs) para análise comparativa:

- ChatGPT (OpenAI, 2024) – modelo baseado em arquitetura *Decoder-Only Transformer*;
- Grok (xAI, 2024) – modelo multimodal recente, também treinado com base em instruções em linguagem natural.

As interações foram realizadas nas versões gratuitas de ambas as plataformas, simulando o ambiente de uso mais acessível a pesquisadores e estudantes.

Além disso, foram utilizadas as ferramentas MATLAB® (para modelagem matemática e plotagem 3D) e Python (para conferência de sintaxe e comparação de resultados).

3.2 Formulação dos *Prompts*

Foram desenvolvidos *prompts* padronizados para três cenários distintos de aplicação:

1. Geração de Imagens: *prompts* descritivos foram empregados para verificar a clareza semântica e o impacto de instruções negativas (ex.: inclusão ou exclusão de elementos visuais).
2. Cidades Inteligentes: *prompts* conceituais foram utilizados para avaliar a capacidade dos modelos em sintetizar e organizar informações sobre tecnologia urbana, governança e sustentabilidade.
3. Aplicação em Robótica: *prompts* técnicos foram criados para gerar códigos baseados no modelo Denavit-Hartenberg de um robô industrial KUKA KR6 R900, permitindo verificar se os modelos seriam capazes de reproduzir a formulação matemática de cinemática direta.

Os *prompts* foram projetados segundo os princípios fundamentais da engenharia de *prompt*: clareza, contexto e relevância semântica, buscando eliminar ambiguidades e otimizar a precisão das respostas.

A escolha de iniciar os experimentos com *prompts* visuais e conceituais teve também uma motivação prática: simular o processo de tradução semântica que ocorre entre comandos humanos e execução robótica. Assim, antes da aplicação direta na modelagem matemática do robô, as etapas anteriores serviram como uma forma de calibrar a clareza linguística dos *prompts*, condição essencial para seu uso futuro em controladores robóticos baseados em linguagem natural.

3.2 Critérios de Avaliação

A análise dos resultados obtidos considerou três critérios principais:

- Clareza e coerência das respostas geradas: verificou-se se o texto ou código produzido mantinha consistência lógica e semântica com o *prompt* original;

- Aplicabilidade prática: os códigos gerados foram testados em ambiente MATLAB para validação sintática e para verificar se poderiam ser utilizados em simulações robóticas;
- Comparabilidade entre modelos: avaliou-se a similaridade e a qualidade das respostas entre o ChatGPT e o Grok, observando variações de precisão e detalhamento.

Os resultados foram documentados por meio de registros textuais e visuais (imagens e gráficos 3D), com o intuito de correlacionar a estrutura dos *prompts* com a qualidade dos resultados obtidos.


4 RESULTADOS E DISCUSSÕES

O primeiro experimento consistiu na geração de uma imagem com base em um prompt descritivo, a fim de avaliar a clareza e a coerência semântica das respostas visuais do modelo de linguagem. Para isso, foi utilizado o comando:

“Modifique essa imagem mantendo o mesmo prompt original: floresta ao amanhecer com raios de sol dourados entre as árvores.”

Esse prompt foi elaborado para conter uma descrição clara, objetiva e internamente coerentes elementos considerados essenciais na engenharia de prompt. A ausência de contradições, como solicitar “raios de sol em uma floresta à noite”, permite que o modelo produza uma representação fiel da intenção do usuário. A escolha desse exemplo busca evidenciar como a precisão linguística influencia diretamente a consistência do resultado gerado pela IA.

Figura 4 – Floresta a noite.



Fonte: Imagem gerada por IA. Plataforma ChatGPT (2024).

No segundo experimento, o objetivo foi avaliar a capacidade do modelo em interpretar restrições negativas em prompts ou seja, instruções que indicam o que não deve aparecer na geração da imagem. O comando utilizado foi:

“Modifique essa imagem, mostrando crianças brincando em um parquinho e evite adultos, crianças ou qualquer pessoa consumindo álcool.”

Inicialmente, o prompt continha apenas a restrição “evite adultos”, o que resultou na geração de uma imagem com uma criança em contexto inadequado. Essa inconsistência demonstrou que prompts com instruções negativas vagas podem levar o modelo a interpretações ambíguas. Após a reformulação do comando, incluindo restrições mais específicas (“evite qualquer pessoa consumindo álcool”), a imagem resultante tornou-se coerente e semanticamente adequada ao contexto proposto.

Esse experimento reforça a importância da precisão e da completude semântica na elaboração de prompts, especialmente quando se busca controlar elementos éticos ou comportamentais nas respostas de modelos generativos.

Figura 5 – Crianças brincando em um parquinho



Fonte: Imagem gerada por IA. Plataforma ChatGPT (2024)

Um exemplo recente importante para crescimento tecnológico são as cidades inteligentes. Um *prompt* para a área,

“Quais são as características que credenciam cidades serem consideradas inteligentes. Cite alguns exemplos no Brasil e no mundo de cidades e quais foram suas credenciais”

Cidades inteligentes (ou *smart cities*) são aquelas que utilizam tecnologias da informação e comunicação (TIC) para melhorar a qualidade de vida dos cidadãos, otimizar a gestão urbana e promover o desenvolvimento sustentável. Elas integram recursos tecnológicos com planejamento urbano e participação cidadã.

As principais características das cidades inteligentes envolvem diversas áreas. A governança inteligente está relacionada à transparência, participação cidadã e oferta de serviços públicos por meio digital. A mobilidade urbana inteligente inclui transporte público eficiente, uso de ciclovias, aplicativos de transporte e semáforos conectados.

Outro aspecto importante é a gestão sustentável dos recursos, que envolve o uso racional de água e energia, bem como o manejo de resíduos com tecnologias inovadoras. Além disso, essas cidades contam com infraestrutura tecnológica avançada, como conectividade em larga escala (Wi-Fi público, redes 5G e dispositivos IoT), sensores e sistemas de análise de dados em tempo real.

A segurança também é um pilar essencial. As cidades inteligentes utilizam câmeras, inteligência artificial e sistemas de resposta rápida para emergências. Na área da educação e saúde, promovem ensino à distância, plataformas digitais, telemedicina e uso de prontuários eletrônicos.

A economia inteligente é marcada pelo incentivo à inovação, apoio a startups e digitalização de processos. Outro fator fundamental é a sustentabilidade ambiental, com ações voltadas à preservação de áreas verdes e redução da emissão de carbono.

Entre os exemplos internacionais de cidades inteligentes, destacam-se:

Barcelona (Espanha): utiliza sensores para iluminação pública, controle de tráfego e gestão de resíduos. A cidade conta com o aplicativo *CityOS* para integrar dados urbanos e oferece Wi-Fi gratuito em áreas públicas.

Copenhague (Dinamarca): possui uma forte ênfase em sustentabilidade, uso intensivo de bicicletas e sistemas inteligentes de energia e transporte. A cidade também se destaca pela colaboração com startups para desenvolver soluções urbanas.

Singapura: é um exemplo de cidade com uso intensivo de sensores e câmeras para gestão urbana. Seu projeto *Smart Nation* promove a integração entre governo, empresas e cidadãos. O sistema de transporte público é altamente eficiente e conectado.

No Brasil, também existem cidades com iniciativas relevantes no campo da inteligência urbana:

Curitiba (PR): pioneira em planejamento urbano, possui um sistema de transporte coletivo integrado, além de programas reconhecidos de coleta seletiva e reciclagem.

São Paulo (SP): conta com projetos de mobilidade urbana inteligente, como faixas exclusivas para ônibus e aplicativos de transporte. Também desenvolve iniciativas de governo digital e dados abertos.

Florianópolis (SC): se destaca como polo de inovação tecnológica, com parcerias entre governo, universidades e empresas. A cidade vem expandindo o Wi-Fi público e a iluminação inteligente.

Salvador (BA): tem investido em segurança pública com monitoramento inteligente. A cidade implantou postes inteligentes com câmeras, Wi-Fi e sensores distribuídos em áreas estratégicas.

Finalmente, ressaltasse algumas dificuldades, como por exemplo:

Prompts complexos, *Prompts* muito longos ou complexos podem confundir o modelo. Viés e preconceitos, nesse caso, Modelos de linguagem podem ser influenciados pelos dados com que foram treinados, reforçando preconceitos existentes. Outra dificuldade que se deve destacar é de existem limitações no modelo, dificuldade que ao longo do tempo devido a maioria da massa de treinamento, que já ultrapassa trilhões de *terabytes*, mesmo com prompts bem elaborados, os modelos de linguagem têm limitações inerentes (Mendonça *et al.*, 2025).

A luz de análises mais científicas, dois modelos de *chatbots* (*Grok free* e *Chatgpt no free*) foram utilizados para geração do modelo Denavit-Hartenberg do robô industrial Kuka R-900 (ressalta-se que, são modelos complexos com diversas matrizes concatenadas, entretanto é o modelo inicialmente para mecanismos mecânicos na década de 40, e foram adotados para modelagem de robôs. A figura 6 apresenta parte do código *MATLAB* do modelo e a figura 7 mostra uma superfície plotada em três dimensões pelo atuador, usando *chatgpt*. Já a figura 8 também mostra parte do código gerado *MATLAB* pelo *Grok* e a figura 9 um exemplo de superfície também em 3 dimensões. Ressalta-se que nesse caso uma versão paga teve resultados similares com versão *free*. Códigos em *Python* também foram gerados, porém devido à similaridade e restrição de espaço não foram apresentados.

A partir desses experimentos, observa-se que a engenharia de prompt não apenas aprimora a geração de conteúdo textual e visual, mas também fornece subsídios linguísticos essenciais para a comunicação com sistemas robóticos inteligentes. Em contextos industriais, por exemplo, um operador poderá utilizar prompts estruturados para instruir um robô

colaborativo sobre tarefas específicas, ajustando parâmetros de movimento, força e prioridade sem a necessidade de programação tradicional.

Figura 6 – Código .M gerado pelo ChatGPT.

```
% Matrizes de transformação U-H
T01 = [cos(theta1) 0 -sin(theta1) 0; sin(theta1) 0 cos(theta1) 0; 0 -1 0 d1; 0 0 0 1];
T12 = [sin(theta2) cos(theta2) 0 a2*sin(theta2); -cos(theta2) sin(theta2) 0 -a2*cos(theta2); 0 0 1 0; 0 0 0 1];
T23 = [cos(theta3) -sin(theta3) 0 a3; sin(theta3) cos(theta3) 0 0; 0 0 1 0; 0 0 0 1];
T34 = [cos(theta4) -sin(theta4) 0 0; 0 0 -1 -d4; sin(theta4) cos(theta4) 0 0; 0 0 0 1];
T45 = [cos(theta5) -sin(theta5) 0 0; 0 0 1 0; -sin(theta5) -cos(theta5) 0 0; 0 0 0 1];
T56 = [cos(theta6) -sin(theta6) 0 0; 0 0 -1 0; sin(theta6) cos(theta6) 0 0; 0 0 0 1];

% Matriz de transformação final
T06 = T01 * T12 * T23 * T34 * T45 * T56;
p0 = [0; 0; 0; 1];
p1 = T06 * p0;


% Coordenadas do efetador final
xfdh(1) = p1(1) / p1(4);
yfdh(1) = p1(2) / p1(4);
zfdh(1) = p1(3) / p1(4);

l = l + 1;
end
end

% Plotagem 3D
figure;
hold on;
scatter3(xfdh, yfdh, zfdh, 50, linspace(1, 10, length(xfdh)), 'filled');
colormap(jet);
```

Fonte: Autores (2025).

Figura 7 – Vetor final em 3D para o braço KUKA KR6 R900




Fonte: Autores (2025).

Figura 8 – Código .M gerado pelo Grok.

```
% Definir os parâmetros Denavit-Hartenberg (D-H) para o KUKA R 400
% [theta, d, a, alpha] em radianos e metros
% Valores hipotéticos baseados em robôs KUKA de 6 DOF
dh_params = [
    0, 0.675, 0.350, -pi/2; % J1 (theta inicial = 0)
    0, 0, 1.150, 0; % J2
    0, 0, 0.041, pi/2; % J3
    0, 1.200, 0, -pi/2; % J4
    0, 0, 0, pi/2; % J5
    0, 0.200, 0, 0 % J6 (ferramenta)
];
```

Figura 7 – Superfície de alcance do KUKA R400.



Fonte: Autores (2025).

A análise dos resultados pode ser dividida em três frentes principais: clareza e precisão dos *prompts*, compreensão e aplicação do conceito de cidades inteligentes e a comparação entre modelos de linguagem (LLMs) na geração de modelos matemáticos aplicados à robótica. Cada um desses pontos revela aspectos importantes sobre o uso de inteligência artificial tanto em tarefas criativas quanto técnicas.

Em relação à clareza dos *prompts*, é evidente que instruções bem elaboradas são determinantes para a obtenção de resultados coerentes. A analogia utilizada, que compara “raios de sol em uma floresta à noite” com a inconsistência de alguns resultados gerados por modelos, ilustra bem como uma instrução ambígua ou contraditória pode comprometer o resultado final. Um exemplo prático citado foi o de uma imagem que deveria mostrar crianças brincando em um parquinho, sem adultos consumindo álcool. A versão inicial do *prompt* restringia apenas a presença de adultos, o que acabou permitindo a geração de uma criança em contexto inadequado. Com o ajuste no *prompt* — eliminando qualquer pessoa consumindo álcool — o resultado tornou-se mais adequado. Isso demonstra como pequenos ajustes na linguagem influenciam diretamente a qualidade da resposta da IA. A engenharia de *prompts*, portanto, torna-se uma habilidade central na interação com modelos generativos, exigindo precisão, clareza e antecipação de ambiguidades.

Em relação ao tema das cidades inteligentes, o texto apresenta uma abordagem bem fundamentada, abordando o conceito como sendo a aplicação de tecnologias da informação e comunicação (TIC) para melhorar a qualidade de vida dos cidadãos, promover sustentabilidade e otimizar a gestão urbana. São discutidas várias dimensões das *smart cities*,

como governança digital, mobilidade urbana eficiente, sustentabilidade ambiental, segurança pública, conectividade e incentivo à economia digital. Exemplos internacionais como Barcelona, Copenhague e Singapura são bem escolhidos, ilustrando o uso de sensores, redes inteligentes, dados abertos e integração entre governo e sociedade. No Brasil, destacam-se Curitiba, São Paulo, Florianópolis e Salvador com projetos voltados à inovação tecnológica, transporte público e segurança urbana. A exposição desses casos demonstra um bom domínio técnico e uma visão crítica sobre o tema, especialmente ao abordar os desafios, como o viés algorítmico e a complexidade de *prompts* em aplicações mais sofisticadas. Também é destacada a limitação intrínseca dos modelos de linguagem, que mesmo com volumes massivos de dados de treinamento, ainda enfrentam dificuldades em lidar com certas nuances contextuais.

Por fim, a comparação entre os modelos de linguagem Grok (versão gratuita) e ChatGPT (também gratuito) na geração do modelo Denavit-Hartenberg para o robô industrial Kuka R-900 revela que ambos os modelos foram capazes de lidar com uma tarefa considerada complexa na engenharia mecânica e robótica. A modelagem D-H envolve a construção de múltiplas matrizes de transformação homogênea, e exige conhecimento técnico para gerar código funcional em MATLAB, além da visualização da superfície tridimensional do atuador do robô. Os resultados indicam que tanto o *Grok* quanto o *ChatGPT* forneceram soluções similares e tecnicamente viáveis, mesmo nas versões gratuitas, o que aponta para um nível elevado de maturidade nos modelos atuais. Apesar de códigos em Python também terem sido gerados, eles não foram apresentados por questões de espaço, o que representa uma limitação na análise comparativa, considerando que Python é amplamente utilizado em ambientes acadêmicos e industriais.

Em síntese, os resultados evidenciam a importância da precisão linguística para o uso efetivo de modelos de linguagem, a relevância crescente das cidades inteligentes no cenário urbano global, e o potencial real das IAs generativas na engenharia aplicada. A integração entre clareza na formulação de instruções e capacidade técnica dos modelos resulta em soluções cada vez mais eficazes para problemas complexos. Recomenda-se, para trabalhos futuros, a inclusão de códigos comparativos em diferentes linguagens e a visualização dos gráficos 3D gerados, a fim de enriquecer a análise técnica e visual das respostas obtidas pelos modelos.

4 CONCLUSÃO

A engenharia de *prompt* demonstrou ser uma ferramenta essencial para otimizar a interação entre humanos e modelos de inteligência artificial, especialmente em contextos complexos como a robótica. Ao permitir que comandos em linguagem natural sejam interpretados com maior precisão, essa abordagem amplia a aplicabilidade de sistemas autônomos em tarefas práticas, desde a geração de imagens até a modelagem matemática de mecanismos. Os exemplos abordados no trabalho evidenciam que a clareza e a estrutura dos *prompts* são fatores críticos para a obtenção de resultados coerentes e funcionais.

Além disso, a comparação entre diferentes modelos de linguagem reforça que, mesmo em versões gratuitas, as tecnologias atuais apresentam elevado grau de precisão e aplicabilidade. A aplicação prática em cidades inteligentes, a construção de modelos de robôs industriais e os experimentos com geração de imagens revelam que a engenharia de *prompt* não apenas potencializa a eficiência das IAs, como também amplia sua acessibilidade e utilidade em setores técnicos e acadêmicos. Profissionais que dominarem essa nova competência estarão mais preparados para enfrentar os desafios do mercado tecnológico.

No campo da robótica, a engenharia de *prompt* tende a desempenhar papel cada vez mais relevante, especialmente no controle de sistemas colaborativos e na automação baseada em linguagem natural. O avanço dessa tecnologia pode permitir que robôs

compreendam instruções complexas de forma contextualizada, reduzindo a dependência de programação explícita e aumentando a interação intuitiva com operadores humanos. Assim, a convergência entre *prompt engineering* e robótica inaugura uma nova etapa da automação inteligente, em que a comunicação entre homem e máquina se torna mais natural, precisa e adaptável.

5 AGRADECIMENTO

O presente trabalho foi realizado com apoio da Coordenação de Aperfeiçoamento de Pessoal de Nível Superior - Brasil (CAPES) - Código de Financiamento 001.

6 REFERÊNCIAS BIBLIOGRÁFICAS

BA, Jimmy Lei; KIROS, Jamie Ryan; HINTON, Geoffrey E. **Layer Normalization**. arXiv preprint arXiv:1607.06450, 2016.

BENDER, Emily M.; GEBRU, Timnit; MCMILLAN-MAJOR, Angelina; SHMITCHELL, Shmargaret. **On the dangers of stochastic parrots: can language models be too big?** In: ACM Conference on Fairness, Accountability, and Transparency, 2021. Anais [...]. [S.l.]: ACM, 2021. p. 610–623.

BROOKS, Rodney. **Flesh and machines: how robots will change us**. New York: Pantheon Books, 2002.

BROWN, Tom B.; MANN, Benjamin; RYDER, Nick; SUBBIAH, Melanie; KAPLAN, Jared; DHARIWAL, Prafulla; NEELAKANTAN, Arvind; SHYAM, Pranav; SASTRY, Girish; ASKELL, Amanda; AGARWAL, Sandhini; HERBERT-VOSS, Ariel; KRUEGER, Gretchen; HENIGHAN, Tom; CHILD, Rewon; RAMESH, Aditya; ZIEGLER, Daniel M.; WU, Jeffrey; WINTER, Clemens; HESSE, Christopher; CHEN, Mark; SIGLER, Eric; LITWIN, Mateusz; GRAY, Scott; CHESS, Benjamin; CLARK, Jack; BERGAMO, Alessandro; SANDERS, Michael; NOLAN, John; RAO, Lilian Weng; PETROV, Sam; GAO, Zheng; BIDERMAN, Stella; AMODEI, Dario; AMODEI, Sam; HERNANDEZ, Daniel; CLIPPER, Tom; RADFORD, Alec; SUTSKEVER, Ilya. **Language models are few-shot learners**. In: Advances in Neural Information Processing Systems (NeurIPS), 2020, [S.l.]. Anais [...]. [S.l.]: Curran Associates, 2020. p. 1877–1901.

BRYNJOLFSSON, Erik; MCAFEE, Andrew. **The second machine age: work, progress, and prosperity in a time of brilliant technologies**. New York: W. W. Norton & Company, 2014.

GOPNIK, Alison. **The gardener and the carpenter: what the new science of child development tells us about the relationship between parents and children**. New York: Farrar, Straus and Giroux, 2016.

GRAVES, Alex. **Generating sequences with recurrent neural networks**. arXiv preprint arXiv:1308.0850, 2013.

HE, Kaiming; ZHANG, Xiangyu; REN, Shaoqing; SUN, Jian. **Deep residual learning for image recognition**. In: IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016, [S.l.]. Anais [...]. [S.l.]: IEEE, 2016.

HOLLAND, John H. **Adaptation in natural and artificial systems**. Ann Arbor: University of Michigan Press, 1975.

KAPLAN, Jared; MCCANDLISH, Sam; HENIGHAN, Tom; BROWN, Tom B.; CHESS, Benjamin; CHILD, Rewon; GRAY, Scott; RADFORD, Alec; WU, Jeffrey; AMODEI, Dario. **Scaling laws for neural language models**. arXiv preprint arXiv:2001.08361, 2020. Disponível em: <https://arxiv.org/abs/2001.08361>. Acesso em: 13 abr. 2025.

LAWGEEX. **Comparing AI to Top Lawyers: The Ultimate Showdown**. 2018. Disponível em: <https://www.lawgeex.com/AlvsLawyer/>. Acesso em: 21 mar. 2025.

LIU, P., YUAN, W., FU, J., JIANG, Z., HAYASHI, H., & NEUBIG, G. (2023). **Pre-train, prompt, and predict: A systematic survey of prompting methods in natural language processing**. *ACM computing surveys*, 55(9), 1-35.

LECUN, Yann. **A path towards autonomous machine intelligence**. *Communications of the ACM*, v. 62, n. 6, p. 56–67, 2019.

MENDONÇA, Márcio; GEROMEL, Guilherme Cyrino; MILANEZ, Fábio Rodrigo; NETO, Ângelo Feracin; LAIA, Marcos Antônio de Matos; VALLIM, Marcos Banheti Rabello; MILANI, Vitor Blanc; SANTOS, Marta Rúbia Pereira dos; GONGORA, Vicente de Lima; AGONILHA, Henrique Cavaliere; CALEGARI, Pedro Henrique; HAIDUK, Andressa; JUNIOR, Kazuyochi Ota; ULIAM, Gabriel Henrique Oliveira; QUEIROZ, Fábio Nogueira de; SANTOS, Ediniel Aparecido Furquim dos; JUNIOR, Francisco de Assis Scannavino. **Inteligências artificiais generativas com Python: fundamentos, aprendizado de máquina, redes neurais clássicas e profundas, transformers e engenharia de prompt para geração de imagens**. In: *Ciência, Tecnologia e Inovação na Perspectiva das Engenharias 2*. Cap. 6, p. 63–76, 2025.

MITCHELL, Melanie. **Artificial intelligence: a guide for thinking humans**. New York: Farrar, Straus and Giroux, 2019.

MIT. **MIT Generative AI Week: Shaping the Future**. Cambridge, MA: Massachusetts Institute of Technology, 2023. Disponível em: <https://cap.csail.mit.edu/members/events-professional-programs/mit-generative-ai-week>.

RADFORD, Alec; NARASIMHAN, Karthik; SALIMANS, Tim; SUTSKEVER, Ilya. **Improving language understanding by generative pre-training**. [S.l.]: OpenAI, 2018.

RADFORD, Alec; WU, Jeffrey; CHILD, Rewon; LUAN, David; AMODEI, Dario; SUTSKEVER, Ilya. **Language models are unsupervised multitask learners**. [S.l.]: OpenAI, 2019. Disponível em: https://cdn.openai.com/better-language-models/language_models_are_unsupervised_multitask_learners.pdf. Acesso em: 21 mar. 2025.

SAMUEL, Arthur L. **Some studies in machine learning using the game of checkers**. *IBM Journal of Research and Development*, v. 3, n. 3, p. 210–229, 1959.

VASWANI, Ashish; SHAZEER, Noam; PARMAR, Niki; USZKOREIT, Jakob; JONES, Llion; GOMEZ, Aidan N.; KAISER, Lukasz; POLOSUHKIN, Illia. **Attention is all you need**. arXiv preprint arXiv:1706.03762, 2017. Disponível em: <https://arxiv.org/abs/1706.03762>. Acesso em: 13 abr. 2025.

Wang, C., Hasler, S., Tanneberg, D., Ocker, F., Joublin, F., Ceravola, A., ... & Gienger, M. (2024, May). **Lami: Large language models for multi-modal human-robot interaction**. In

Extended Abstracts of the CHI Conference on Human Factors in Computing Systems (pp. 1-10).

YIU, Eunice; KOSOY, Eliza; GOPNIK, Alison. **Imitation versus innovation: what can children do that large language and language-and-vision models cannot (yet)?** Department of Psychology, University of California - Berkeley, 2023.

ZADEH, Lotfi A. **Fuzzy sets**. *Information and Control*, v. 8, n. 3, p. 338–353, 1965.

Zhou, X., Zhang, Y., Cui, L., & Huang, D. (2020, April). **Evaluating commonsense in pre-trained language models**. In *Proceedings of the AAAI conference on artificial intelligence* (Vol. 34, No. 05, pp. 9733-9740).